

YouTube 影片流量預測與留言互動特徵分析

資料探勘導論期末專題提案報告

一、研究動機與目的

YouTube 是當前最具影響力的影音平台之一。對創作者而言，影片發布後的觀看數成長速度、按讚數與留言互動率，會直接影響影片能否被更多觀眾看見。若能在影片發布早期，根據影片本身資訊與初期互動數據預測後續流量變化，將有助於理解哪些因素與影片擴散有關。

本研究的核心問題為：**能否透過影片公開資料、早期流量變化與留言互動特徵，預測 YouTube 影片在未來一段時間內的觀看數成長表現。**

研究目標：

1. 建立 YouTube 影片資料蒐集流程，取得影片靜態資訊、時間序列流量資料與留言資料。
2. 設計可實際取得且具有分析意義的特徵。
3. 建立多種預測模型，比較不同類型方法（表格式機器學習與時間序列深度學習）對流量分類的效能。
4. 分析哪些特徵對流量預測較有幫助，特別是留言情緒特徵是否能提升模型表現。

二、研究資料

本研究資料由自行撰寫之 Python 爬蟲程式蒐集，資料來源為 YouTube 公開頁面可取得之資訊。所有資料以 JSON、CSV、JSONL 等文字檔案儲存，便於以 Pandas 處理。

2.1 影片靜態資料

以 JSON 儲存，video_id 為 key。欄位：

- video_id：影片唯一識別碼
- title：影片標題（用於計算 title_length）
- channel_id：頻道識別碼（用於爬取頻道訂閱數）

- `publish_time`：發布時間（用於計算 `publish_hour`）
- `duration_seconds`：影片長度（秒）
- `category`：影片分類
- `tag_count`：標籤數量（爬取時直接計數，反映標題 SEO 積極度）
- `is_shorts`：是否為 Shorts 短影片（判定方式見 4.1）

2.2 時間序列流量資料

以 CSV 長表格式儲存，每列代表一部影片在某時間點的狀態。欄位：

- `video_id`、`crawl_time`、`time_since_publish_minutes`
- `view_count`、`like_count`、`comment_count`（LSTM 時序輸入與衍生特徵來源）
- `subscriber_count`：頻道訂閱數（用於計算 `log_subscriber_count`）
- `video_status`：影片狀態（用於過濾不可用影片）

2.3 留言資料

每部影片獨立儲存為 JSONL 檔案。欄位：

- `video_id`、`comment_id`（去重用）
- `comment_text`：留言內容（情緒分析輸入）
- `comment_like_count`：留言按讚數（用於計算 `top_comment_like_ratio`）
- `crawl_time`

三、資料儲存架構

```
youtube_traffic_project/
├── data/
│   ├── raw/
│   │   ├── static/videos_static.json
│   │   ├── timeseries/video_stats_all.csv
│   │   └── comments/by_video/{video_id}.jsonl
│   ├── processed/
│   │   ├── tabular_features.csv      # LightGBM 用
│   │   ├── sequences/               # LSTM 用，每部影片一個 npy
│   │   └── label_dataset.csv
│   └── split/{train,valid,test}.csv
├── src/{crawler,preprocessing,modeling,utils}/
├── models/
└── results/
```

靜態資料用 JSON 因查詢頻繁、key-value 結構自然；時序資料用 CSV 長表因 Pandas groupby 操作直接；留言用 JSONL 因逐行讀取可避免記憶體壓力。

四、分析方式

4.1 資料蒐集

建立影片清單：來源包含發燒影片、搜尋結果與指定頻道近期影片。每部新影片加入清單時，透過以下方式判定是否為 Shorts：對 `https://www.youtube.com/shorts/{video_id}` 發送 HTTP 請求（不跟隨重新導向），回傳 303 See Other 為長影片，回傳 200 OK 為 Shorts，並記入 `is_shorts`。此方法不需 API key，可自動標記。

由於 Shorts 與長片在演算法推送與流量行為上差異極大，本研究分開建模以避免混合雜訊。

定期爬取流量：每 **5–10 分鐘** 更新一次觀看數、按讚數、留言數與訂閱數（間隔縮短以提供更密集的時序輸入給 LSTM）。

定期爬取留言：每 2 小時抓取一次，每部影片保留前 200 則熱門留言。

4.2 資料清理

- 同時間點重複資料保留最新一筆。
- 時序中間少數缺失以線性插補；整段缺失則排除該影片。
- 影片被刪除或轉為私人則不納入訓練。
- 觀看數使用 $\log_{1p}$ 轉換以降低長尾偏斜。
- Shorts 與長影片分成兩個獨立資料集，分別建模。

4.3 特徵設計

特徵分為兩套：給 LightGBM 使用的**表格特徵**，與給 LSTM 使用的**時間序列輸入**。

表格特徵（供 LightGBM，共 12 個）

類別	特徵	為什麼用
影片基本	duration_seconds	長度影響觀看完成率與推薦行為
	category	不同分類流量分布差異大
	publish_hour	發布時段影響初期曝光
	is_shorts	Shorts 與長片演算法行為截然不同
	title_length	反映標題資訊量，與點擊率相關
	tag_count	標籤數量反映創作者的 SEO 積極程度
頻道	log_subscriber_count	訂閱規模是初始曝光最強控制變項；取 log 因分布偏斜
早期流量	view_growth_rate_1h	首小時成長率是後續擴散最直接的訊號
	engagement_rate_early	(likes+comments)/views，反映觀眾互動強度
	views_per_minute_early	初期速度，與訂閱數規模解耦
留言	comment_sentiment_score	留言整體情緒傾向（開源模型輸出，見下方）
	top_comment_like_ratio	最熱門留言按讚數 / 觀看數，反映是否有「神留言」帶動傳播

時間序列輸入（供 LSTM）

每部影片整理為長度 T 的序列，每個時間步包含 3 個特徵： $(view_count, like_count, comment_count)$ ，以各自最大值歸一化。T 取影片前 3 小時的爬取點

(5-10 分鐘間隔，約 18–36 步)。LSTM 直接從原始序列中學習成長加速度、平台期等時序結構，不需人工轉換成成長率。

留言情緒分析

使用開源中文預訓練模型（`uer/roberta-base-finetuned-jd-binary-chinese`），對每部影片的 200 則留言批次推論，輸出各留言情緒正向機率（0–1），彙整為平均值（`comment_sentiment_score`）。選此模型因其已在中文評論語料微調、可離線執行、不依賴付費 API。

4.4 預測目標

設定為**二元分類任務**：依「發布後 24 小時觀看數成長率」分為高成長與低成長兩類，以樣本中位數為分界。

五、預計嘗試的方法

三種類型的模型，每種代表不同的歸納假設，互相比較才有意義：

5.1 基準模型：Logistic Regression

線性模型，作為比較基準，確認後續模型確實有非線性增益。輸入為表格特徵。

5.2 表格模型：LightGBM

梯度提升決策樹，適合結構化表格資料。選 LightGBM 因其訓練速度快、原生支援類別變項（`category`）、可輸出 SHAP 值供特徵解釋。輸入為完整表格特徵。

5.3 時間序列模型：LSTM

對時序輸入建模，捕捉成長加速度、爆發模式等表格特徵無法表達的時序結構。架構為 2 層 LSTM + Dropout + 全連接輸出層，以 BCELoss 訓練。輸入為 $(T \times 3)$ 的歸一化時序序列。

5.4 整合模型：Stacking Ensemble

以 LightGBM 與 LSTM 的預測機率作為 meta-features，以 Logistic Regression 作為 meta-learner 進行 stacking。兩個 base learner 捕捉互補資訊：LightGBM 掌握靜態特徵與早期互動，LSTM 掌握時序動態，meta-learner 學習如何加權兩者。

六、方法特色與創新性

- 1. **以 HTTP 狀態碼自動判定 Shorts 與長影片**：公開 API 不直接提供此標記，本方法無需 API key 即可自動判定，並對兩種型態分開建模以消除混合雜訊。
- 2. **表格模型與時序模型的 Stacking**：LightGBM 與 LSTM 捕捉互補資訊，stacking 整合兩者而非單純選一。
- 3. **留言特徵走「少而精」路線**：以開源預訓練模型生成情緒分數，並收斂為兩個高層次指標，避免維度災難。
- 4. **分階段特徵組合對照實驗**：量化靜態特徵、早期流量、留言情緒三類特徵各自對預測效能的邊際貢獻（見第七節）。

七、模型效能評估方式

指標	為什麼用
F1-score	主要指標。高低成長類別即使以中位數切分仍可能略有偏差，F1 同時兼顧 precision 與 recall
AUC-ROC	衡量模型排序能力，不受分類門檻影響，便於跨模型比較

資料切分：依時間順序切分（早期影片為訓練集、晚期為測試集），避免時序洩漏。

對照實驗（回答「各類特徵是否有幫助」）：

組合	特徵
A	影片基本特徵 + 頻道特徵
B	A + 早期流量特徵（含 LSTM 時序輸入）
C	B + 留言情緒特徵

各組合分別在 LightGBM、LSTM、Stacking 三個模型上跑，比較 F1 與 AUC 的差異，量化每類特徵的邊際貢獻。

八、預期成果

1. 建立可重複執行的 YouTube 資料蒐集流程，包含 Shorts 自動判定與高頻時序爬取。
2. 完成表格特徵集與 LSTM 時序輸入兩套資料處理流程。
3. 完成 Logistic Regression、LightGBM、LSTM、Stacking 四個模型的比較。
4. 透過對照實驗量化靜態特徵、早期流量特徵、留言情緒特徵各自的邊際貢獻。
5. 產出 SHAP 特徵重要性分析，找出影響影片成長的關鍵因素。

九、預定研究流程

1. 建立爬蟲與資料夾架構，實作 Shorts 判定邏輯。
2. 蒐集影片靜態資料與初步影片清單。
3. 定期蒐集時間序列流量資料（持續 2–3 週）。
4. 蒐集留言並以開源模型批次計算情緒分數。
5. 資料清理、表格特徵工程與 LSTM 時序資料整理。
6. 訓練模型、執行對照實驗、評估效能。
7. 撰寫期末報告與視覺化結果。

十、結論

本專題以 YouTube 影片流量預測為主題，透過公開可取得之影片資訊、高頻時間序列流量資料與留言互動資料，建立一套完整的資料探勘分析流程。方法設計同時包含表格式機器學習（LightGBM）與時間序列深度學習（LSTM），並以 Stacking 整合兩者的互補優勢。透過對照實驗可具體回答「留言情緒特徵是否能提升 YouTube 影片流量預測效能」這一核心問題。