


YouTube 影片流量預測 與留言互動特徵分析

資料探勘導論 期末專題提案

張哲維 張子善 林鈺紳 蔡秉融



大綱

01 研究動機與目的

02 研究資料

03 分析方式

04 預計嘗試的方法

05 方法特色與創新性

06 模型效能評估方式

07 預期成果


01

研究動機與目的



動機

觀看數成長示意（發布後 48 小時）



1

YouTube 是最大的創作者舞台

影音平台上創作者與觀眾交流最密集的場域

2

早期表現決定流量

發布後數小時的數據直接影響演算法推薦排序

3

缺乏開放分析工具

目前缺乏簡單可重複的工具分析影片成長行為

核心問題與研究目標

「能否透過影片公開資料、早期流量與留言互動特徵，預測 YouTube 影片的觀看數成長表現？」

目標 1

建立 YouTube 爬蟲流程
靜態資訊 / 時序流量 / 留言資料

目標 2

設計具分析意義特徵
需有清楚的理論假設

目標 3

比較傳統機器學習 (LightGBM)
與深度學習 (LSTM) 的效能

目標 4

找出哪類特徵最有貢獻
透過分階段對照實驗量化

02

研究資料



資料來源與三大類別

Python 爬蟲

STATIC

靜態資訊

JSON

影片不會變動的資料(或變動不重要)
如：影片標題、影片長度、是不是shorts

TIME

時序流量

CSV

影片每個時間點的資料
每 5-10 分鐘更新

COMMENT

留言資料

JSONL

影片下的留言(取前 200 則)
每 2 小時爬取一次

三類資料欄位一覽

靜態資訊 (JSON)

video_id
title
channel_id
publish_time
duration_seconds
category
tag_count
is_shorts

時序流量 (CSV)

crawl_time
time_since_publish
view_count
like_count
comment_count
subscriber_count
video_status

留言資料 (JSONL)

video_id
comment_id
comment_text
comment_like_count
crawl_time

HTTP 狀態碼自動判定 Shorts vs 長影片

HTTP GET youtube.com/shorts/{id}



判斷 HTTP 回應狀態碼



303 See Other
長影片

200 OK
Shorts

分開建模（長影片）

分開建模（Shorts）

無需 API Key

一行 HTTP 請求自動判定，完全不依賴付費服務

消除演算法雜訊


Shorts 與長片流量行為差異大，混用污染模型

可自動化整合

建立影片清單時即時判定，無需事後人工標記

03

分析方式



分析流程總覽

①

資料 蒐集

爬蟲 + Shorts
自動判定

②

資料 清理

去重 / 插補
log1p 轉換

③

特徵 工程

12 個表格特徵
+ 時序序列

④

模型 訓練

LR / LGB /
LSTM / Stack

⑤

模型 解釋

SHAP +
對照實驗

每個階段都有明確輸入與輸出，確保流程完整可重複執行

表格特徵設計（共 12 個）

影片基本（6）

duration_seconds
category
publish_time
is_shorts
title_length
tag_count

頻道（1）

log_subscriber_count

早期流量（3）

view_growth_rate_1h
engagement_rate_early
views_per_minute_early

留言情緒（2）

comment_sentiment_score
top_comment_like_ratio

LSTM 時序輸入設計

輸入矩陣 $T \times 3$

	view_count	like_count	comment_count
t=1	...	...	...
t=2	...	...	...
t=3	...	...	...
t=4	...	...	...
t=T	...	...	...

T = 前 3 小時爬取點 (約 18–36 步)

每時間步輸入 3 維: (views, likes, comments)

各維度以自身最大值歸一化, 消除量綱差異

LSTM 自動學習成長加速度、爆發點、平台期

與 LightGBM 互補: 表格抓靜態、LSTM 抓動態

留言情緒分析

uer/roberta-base-finetuned-jd-binary-chinese

每部影片
前 200 則留言



RoBERTa
批次推論



comment_sentiment_score
(0-1 平均情緒分數)

開源可離線

不依賴付費 API，本地即可推論執行

中文語料微調

已 fine-tune 過，適合中文留言

降低維度

彙整為 2 個高層次指標，避免維度
災難

04

預計嘗試的方法



四種模型一覽

LR

Logistic Regression

線性基準
確認非線性增益是否真實存在

LGB

LightGBM

表格資料主力
原生支援 SHAP 特徵解釋

LSTM

LSTM

時序模型
捕捉成長動態與爆發模式

Stack

Stacking Ensemble

整合 LGB + LSTM
Meta-learner 學習最佳加權

每種模型代表不同歸納假設

互相比較才有意義


LR：確認非線性增益是否真實存在

LightGBM：表格特徵 + SHAP 可解釋性

LSTM：原始時序 → 自動學習動態模式

Stacking：整合互補優勢，提升穩定性

Stacking 架構圖



05

方法特色與創新性



四大方法特色

01

HTTP 狀態碼自動判定 Shorts

不需 API Key，使用 GET 判斷 SHORT 或長影片，分開建模。

02

表格 ML + 時序 DL 的 Stacking

LightGBM 與 LSTM 互補資訊，比單一模型更穩定

03

留言特徵降維

開源模型生成情緒分數，收斂為 2 個維度的指標

04

分階段對照實驗

量化靜態特徵、早期流量、留言情緒各自的貢獻

四大方法特色

01

HTTP 狀態碼自動判定 Shorts

不需 API Key，一行請求自動分流，分開建模消除雜訊




303

四大方法特色

01

HTTP 狀態碼自動判定 Shorts

不需 API Key，一行請求自動分流，分開建模消除雜訊



200

四大方法特色

01

HTTP 狀態碼自動判定 Shorts

不需 API Key，一行請求自動分流，分開建模消除雜訊

02

表格 ML + 時序 DL 的 Stacking

LightGBM 與 LSTM 捕捉互補資訊，整合比單一模型更穩定

03

留言特徵少而精路線

開源預訓練模型生成情緒分數，收斂為 2 個高層次指標

04

分階段對照實驗

量化靜態特徵、早期流量、留言情緒各自的貢獻

06

模型效能評估方式



評估指標與對照實驗

F1-score

主要指標

同時兼顧 Precision 與 Recall

AUC-ROC

輔助指標

衡量排序能力，不受分類門檻影響
便於跨模型公平比較

對照實驗——量化各類特徵的貢獻

A

影片基本特徵 + 頻道特徵

B

A + 早期流量特徵（含 LSTM 時序輸入）

C

B + 留言情緒特徵（完整版本）

依時間順序切分資料集（早期影片訓練，晚期影片測試），避免模型偷看到答案

07

預期成果



預期成果與時程規劃

- 1

可重複的 YT 爬蟲流程（含 Shorts 判定）
- 2



特徵集 + LSTM 時序資料兩套處理流程
- 3

四模型效能比較（LR/LGB/LSTM/Stack）
- 4

對照實驗：量化各類特徵的邊際貢獻
- 5

SHAP 特徵重要性分析，找出關鍵因素

預計時程



Q&A

歡迎提問與建議

Thank you for your attention



本次提案重點

- 1 YouTube 影片流量 × 二元分類預測
- 2 自行爬蟲 + HTTP Shorts 自動判定
- 3 12 個表格特徵 + LSTM 時序輸入
- 4 四模型比較 + Stacking 整合
- 5 F1 / AUC 評估 + 分階段對照實驗